

Conditional VAE-based Extreme Seismic Waveform Generation

극한 지진파 합성을 통한 내진 설계 데이터 증강

Team K8 · 이다슬(2022320085) 이태라(2022100096) 박재형(2024131505) 곽준우(2022170807)

참고문헌

- [1] P. Ren et al., "Learning Physics for Unveiling Hidden Earthquake Ground Motions via Conditional Generative Modeling," *arXiv preprint arXiv:2407.15089*, 2024.
- [2] Z. Bi, N. Nakata, R. Nakata, P. Ren, X. Wu, and M. W. Mahoney, "Advancing Data-Driven Broadband Seismic Wavefield Simulation with Multiconditional Diffusion Model," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 63, pp. 1-9, 2025, Art no. 3591881, arXiv:2501.14348.
- [3] T. Wang, D. Trugman, and Y. Lin, "SeismoGen: Seismic Waveform Synthesis Using Generative Adversarial Networks," *arXiv preprint arXiv:1911.03966*, 2021.
- [4] Z. Kong, W. Ping, J. Huang, K. Zhao, and B. Catanzaro, "DiffWave: A Versatile Diffusion Model for Audio Synthesis," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 21943-21954, arXiv:2010.05646.
- [5] E. Perez, F. Strub, H. De Vries, V. Dumoulin, and A. Courville, "FiLM: Visual Reasoning with a General Conditioning Layer," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018, arXiv:1709.07871.
- [6] L. Birnbaum et al., "Temporal FiLM: Capturing Long-Range Dependencies with Time-Variant Feature-Wise Linear Modulation," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, arXiv:1909.06628.
- [7] R. Yamamoto, J. Juvela, and S. Takamichi, "STFT Spectral Loss for Training a Neural Speech Waveform Model," *arXiv preprint arXiv:1810.11945*, 2019.
- [8] S. M. Mousavi, W. L. Ellsworth, W. Zhu, L. Y. Chiaraluze, D. P. Beroza, and G. C. Beroza, "STEAD: A Global Earthquake Signal Dataset for Machine Learning," *IEEE Access*, vol. 7, pp. 108124-108142, 2019.

MOTIVATION

대형 지진 데이터의 필요성

— 세가지 구조적 문제: 피해 규모 · 데이터 불균형 · 시뮬레이션 비용

① 왜 대형 지진이 치명적인가

01 ML 기반 자동 탐지의 발전

최근 수년간 기계학습 기반 자동 탐지 방법이 개발되어
정확도와 효율이 크게 향상

02 정확도는 데이터에 달려 있다

이 방법들의 성능은 수만 건 이상의
고품질 라벨링 훈련 데이터 확보에 직접 의존

03 딜레마 - 대형 지진은 데이터가 없다

$M \geq 4$ 대형 지진은 발생 빈도가 낮아
충분한 고품질 라벨 데이터가 본질적으로 부족

04 해법 - 합성 데이터 증강

소량의 실제 데이터만 있어도
생성형 AI로 합성 파형을 만들어 훈련 데이터 보완

→ 프로젝트의 출발점

SeismoGen (Wang et al., 2021) · arXiv:1911.03966


59,259

2023 튀르키예 대지진 사망자 (M7.8)

② 데이터 불균형의 정량 근거

STEAD (Stanford Earthquake Dataset)

1.2 M Labeled Waveform. 450 k Earthquakes. 19,000 Hours of Data.



1.2 M


라벨 파형

450 k

지진 이벤트

19,000h

데이터



$M \geq 4$ 구간 = 전체의 단 1.4%
가장 필요한 데이터가 가장 부족한 구조적 모순

③ 왜 AI 생성모델인가

대안과 그 한계

물리 기반 시뮬레이션

128 GPU × 6h

시나리오 1회 / 5Hz / SF 단일 지역
(CGM-GM 논문 기준)

× 고주파(10Hz+)로 갈수록 비용 급증

→ 고주파 영역: 건물 구조물에 더 직접적인 피해

× 다양한 시나리오 대응 불가

— VS —

학습된 AI 생성모델

< 1분 / GPU 1개

학습 후 새로운 조건에 즉시 적용

✓ 다양한 M · 거리 · 지역 조건

✓ 수 초 내 새 시나리오 생성

생성모델 기반 지진파 합성의 흐름

— GAN → VAE → Diffusion 의 진화와 각 단계의 한계, 그리고 우리의 위치

2021

arXiv:1911.03966

SeismoGen

CONDITIONAL GAN

KEY IDEA

- 지진 탐지 ML 모델의 정확도가 고품질라벨 데이터 확보에 달려있다는 문제의식
- **Conditional GAN**으로 P/S파 포함
- 3성분 지진파 시계열을 최초 합성
- 오클라호마 데이터로 탐지 성능 향상 입증

LIMITATION

- × Mode collapse — 다양성 부족
- × 관측소별 별도 모델 학습 필요, 단일 지역·단일 규모 범위로 한정
- × 조건 변수 부족 → 3D 파동 전파 미반영

2024

★ OUR BASELINE

arXiv:2407.15089

CGM-GM

CONDITIONAL VAE + STFT

KEY IDEA

- GAN의 Mode collapse 극복 위해 **VAE** 도입
- STFT(Short-Time Fourier Transform) : 신호를 짧은 구간(window)으로 잘라서 각 구간마다 FFT(주파수 분석)를 수행
- VAE로 진폭만 생성됨 ; 복원을 위해서는 위상 필요 → Griffin-Lim으로 위상 생성

LIMITATION

- × Griffin-Lim 위상 복원 → 스파이크·왜곡
- × Gaussian 잡재 분포 → 고주파 스무딩
- × $M < 4$ 소형 지진 5,108개만 학습
- × 샌프란시스코 단일 지역 — 일반화 미검증

2025

SOTA

arXiv:2501.14348

CGM-Wave

DIFFUSION + PRM

KEY IDEA

- CGM-GM의 두 구조적 한계를 **Diffusion**으로 정면 돌파
- 고주파 영역까지 정밀한 진폭 스펙트럼 생성
- 적응형 위상 복원(PRM)으로 Griffin-Lim 아티팩트 완전 제거

LIMITATION

- × 학습/추론 비용 수백~수천 GPU 시간
- × Colab 환경에서 재현·확장 비현실적
- × 경량화·모듈화 어려움

OUR POSITIONING

CGM-GM 채택

VAE 백본 유지 · 경량·재현 가능



한계 ① 위상

HiFi-GAN → Griffin-Lim 대체



한계 ② 스무딩

Spectral Loss → 고주파 보존



한계 ③ 일반화

STEAD 전 지구 · $M \geq 4$ 검증

지진파 도메인 지식 & CGM-GM의 설계 선택


지진파의 물리적 특성과 1D의 한계

P파와 S파의 도달


지진파는 비정상성(Non-stationary) 신호
시간에 따라 주파수 특성이 급격히 변하는 특성

- P파: 가장 먼저 도착, 고주파, 저진폭
- S파: 뒤늦게 도착, 저주파, 고진폭 (주요 피해)

1차원 파형(Time Domain)만으로는 모델이 복잡한
주파수 변화를 정교하게 학습 불가



STFT: Time to Frequency Transition



왜 2차원인가?

STFT(단시간 푸리에 변환)는 지진파를 2차원 스펙트로그램 이미지로 변환

: 짧은 시간 내의 복잡한 주파수 정보를 표현 가능,

CNN 계열 모델이 패턴을 인식하기 좋은 형태

VAE encoder 에 변환된 2D 정보를 주입

문제 :

VAE 디코더가 2D 스펙트로그램(진폭)을 복원
→ Griffin-Lim 알고리즘이 수학적으로 위상을 '추정'

스펙트로그램 + 추정된 위상을 합쳐서(Inverse STFT)
→ 1D 파형으로 복구

CGM-GM

STFT

Split into
진폭 + 위상
(위상 정보: 매우
복잡)

VAE

Condition

(M / Distance / Depth / Lat, Lon)
바탕으로
"진폭" 정보만 복원

Griffin-Lim

VAE가 만든
진폭으로 누락된
위상 추정

Inverse STFT


진폭 + 위상
→ 1차원 시간
도메인의 합성
지진파

원본 지진파: 시간 → 진폭 (1D)
FFT 결과: 주파수 → 에너지 (1D)
STFT 결과: 시간 × 주파수 →
에너지 (2D)

평가

파이프라인

CGM-GM VAE 백본 유지 · FiLM conditioning · Loss 함수 재설계 · HiFi-GAN 도입



FiLM 조건 임베딩 강화

— 지진 도메인에서 FiLM을 처음 체계적으로 적용

조건 정보를 레이어마다 주입

기존 한계

condition이 입력단에서만 주입
→ 점차 레이어에서 조건 정보 손실

FiLM 효과

γ 는 진폭 특성 스케일링, β 는 주파수 분포 이동
→ 물리적 차이를 내부 표현에 직접 반영

이론 근거

TFiLM (NeurIPS 2019)
→ 1D 오디오 시계열에서 효과 검증

구현 비용

FiMLayer 한 줄 추가 · CNN 블록 구조 무변경

핵심 수식

$\gamma, \beta = \text{FiLMGenerator}(c)$
 $h' = \gamma(c) \cdot h + \beta(c)$

평가 방법

1. PGV 분포 비교



PGV(Peak Ground Velocity)는
파형의 최대 진폭값 M

M이 클수록 PGV는 커지기 때문에
생성된 파형의 M이 커질수록
PGV도 커지는지 물리적으로 확인

2. 잠재 공간 시각화

VAE의 잠재공간 z를
2D로 압축해서 그려보는 방법으로 확인

FiLM이 잘 작동했다면,
M별로 군집이 분리되어 나타남



Spectral Loss 설계

— 고주파 스무딩(Over-smoothing) 직접 공략 및 물리적 에너지 분포 복원

기존 손실 함수

$$L = L_{recon} + \beta L_{KL} + \alpha L_{waveform}$$

Reconstruction Loss: 생성된 데이터가 실제 데이터와 비슷하도록 학습

- 평균적인 spectrogram 복원 선호

KL Divergence Loss: latent space의 정규화

- sharp하고 irregular한 고주파 특징이 노이즈로 처리되어 희석됨

Waveform Loss: 시간영역에서 비교하여

생성 waveform과 실제 waveform 사이 차이를 줄임

- 전체 waveform 평균 형태는 맞아도 고주파 transient는 손실될 수 있음

Over-
Smoothing
발생

제안: Spectral Loss 추가

$$L_{total} = L_{recon} + \beta L_{KL} + \alpha L_{waveform} + \lambda_{spec} L_{spectral}$$

시간 영역 뿐 아니라 주파수 영역에서도 supervision 수행

고주파 디테일을 보존하고 스무딩 문제를 완화

고주파 보존 성능 평가

- 5~15Hz 대역 FAS residual 비교
- residual 감소 여부 측정
- over-smoothing 완화 검증

Spectral Loss의 하이브리드 구조

FAS 기반 전역 손실 (L_{logFAS})

FAS (Fourier Amplitude Spectrum)
: 각 주파수 성분의 에너지 크기 표현

smoothing 발생시, 고주파 에너지가 감소하고 FAS 곡선의 고주파 영역이 아래로 처짐

→ 실제와 생성의 FAS를 직접 비교하여 고주파 에너지가 부족하면 loss 증가

→ “고주파가 충분히 존재하는가?”

MR-STFT 기반 국소 손실 ($L_{MR,lin} + L_{MR,log}$)

STFT: waveform을 시간, 주파수 두 축으로 동시에 분석

smoothing 발생시, timing이 흐려지고 peak가 둥글어짐.

→ Multi-Resolution: 여러 window size와 여러 시간 해상도를 동시에 사용하여 짧은 transient와 긴 구조를 동시에 학습

→ “고주파가 언제 나타나야 하는가?”

추가 전략

1. Log Scaling: $L_{log} = \|\log S - \log \hat{S}\|$

기존 MSE: 저주파 오차는 크게 반영, 고주파 오차는 거의 무시

→ 작은 값의 차이는 상대적으로 확대함으로 약한 고주파 요소까지 적극적으로 복원

2. HF Boost: $w(f > 10Hz) = 1.5 \sim 3.0$

기존: 논문에서 13~15Hz 영역에서 성능 저하 보고

→ 고주파 영역에 추가 가중치 부여함으로 해당 영역 loss를 증가시켜 모델이 고주파 mismatch를 무시 불가능하게 함. 고주파 underestimation 억제


HiFi-GAN으로 Griffin-Lim의 위상 복원 문제 보완

— 음성 파형을 다루는 Vocoder를 지진파에 적용

HiFi-GAN?

진폭 정보만을 가진 mel-spectrogram 형식의 음성 데이터를 waveform으로 변환하는 모델

HiFi-GAN의 구조



Griffin-Lim의 한계

지진파의 특성을 학습하지 않고 진폭에 맞는 위상을 반복적으로 추정하여 복잡한 위상에서 스파이크나 왜곡 발생

HiFi-GAN의 장점

데이터를 학습하여 transient와 oscillation 구조 등의 지진파 특성을 더 자연스럽게 복원
지진파와 음성 데이터 모두 1차원 시계열 데이터이므로 지진파에 적용 가능

MRF

다양한 receptive field로
서로 다른 시간 범위의 패턴을
동시에 학습

짧은 transient와 긴 oscillation 등
지진파의
Multi-scale temporal
structure를 잘 학습함

MPD

서로 다른 주기를 기준으로
반복적인 파형의 구조를 판별

지진파의
주기적인 진동 패턴을
잘 학습함

MSD

서로 다른 시간 Scale에서
연속적인 패턴을 기준으로
파형을 판별

지진파의
local transient와
전체적인 waveform의 흐름을
함께 학습함

성능 평가

HiFi-GAN이 Griffin-lim의 위상 복원 문제를 개선했는지 확인하기 위해
동일한 spectrogram을 griffin-lim과 hifi-gan에 각각 입력하여 얻은 결과를 비교

1. Waveform 비교

- 초기 P파 onset 구조 유지 여부
- 진동 구조
- noise artifact 감소 여부

2. 정량적 비교

- 원본과의 STFT loss
- SNR(Signal-to-Noise Ratio)
- Cross-Correlation

HiFi-GAN으로 Griffin-Lim의 위상 복원 문제 보완

— 음성 파형을 다루는 Vocoder를 지진파에 적용

1. Generator의 input dimension과 upsampling 비율을 linear STFT spectrogram에 맞게 수정

input_channels = n_fft/2 + 1
Upsample_rates : hop_length 고려

2. mel-spectrogram Loss를 linear STFT spectrogram Loss로 수정

spectral convergence loss + log magnitude loss

$$L_{STFT} = L_{sc} + L_{mag}$$

$$L_{STFT} = \frac{\|S - \hat{S}\|_F}{\|S\|_F} + \|\log S - \log \hat{S}\|_1$$

3. MPD 수정

기존 구조

periods = [2, 3, 5, 7, 11]

수정 내용

- 기존 period는 음성 데이터의 짧은 주기 구조에 맞춰 촘촘하게 설계됨
- 지진파는 긴 진동 구조를 가지므로 약 0.1~0.5초 범위를 반영할 수 있도록 주기를 10, 20, 50 으로 설정

4. MSD 수정

음성 데이터의 sampling rate : 22kHz

지진파 데이터의 sampling rate : 100Hz

기존 구조

- 3가지 sub-discriminator (원본, 1/2 downsample, 1/4 downsample)
- 내부 레이어: kernel_size=41, stride=4를 반복

문제점

- 낮은 sampling rate로 인해 기존 MSD의 다운샘플링과 넓은 범위의 커널을 적용하면 시간 해상도의 과도한 손실 발생

수정 내용

- 1/4 sub-discriminator 제거
- kernel size 7-11, stride 1 또는 2로 수정
- 초기 P파의 급격한 변화가 약 0.07초 이내에 나타난다고 알려져 있기 때문에 이를 보존하기 위해 kernel size를 7로 시작
- 작은 kernel로 감소한 receptive field는 dilation을 증가시켜 보완하며, 이를 통해 장기 저주파 진동 구조를 학습

평가 설계

1단계 : 물리적 현실성 검증(TSTR)

Train on Synthetic, Test on Real

탐지 모델(EQTransformer)

지진학 분야에서 현재 가장 널리 쓰이는 딥러닝 기반 지진 탐지 모델

Train :

실제 데이터 배제, 오직 제안 모델이 생성한
합성 $M \geq 4$ 데이터로만 훈련 진행

Test :

한 번도 보지 못한 실제 $M \geq 4$ 지진 기록에 대해
탐지 성능 측정

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{Total}}, \quad \text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

품질이 증명된
합성 데이터

2단계 : 실무적 실효성 검증 (Augmentation)

r배율 증강

r10 증강: 가짜 ($n * 10$) + 진짜 n개

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

	G_{10}	G_{20}	G_{40}	G_{60}	G_{100}
r_0	55.29	69.82	88.36	90.28	92.49
r_1	43.79	58.88	86.90	83.58	92.49
r_{10}	37.09	75.83	93.93	91.72	94.55
r_{50}	50.23	85.02	94.83	92.93	94.38
r_{100}	55.39	83.19	95.02	92.73	94.42
r_{200}	59.48	83.25	94.92	92.53	93.91
r_{300}	59.22	84.63	94.43	92.73	94.25

r 배율 증가에 따른
재현율 상승을 확인